

Hop 기반 가중 앙상블을 통한 클래스 불균형 해결

박용욱⁰¹, 정재균², 김정은²¹인하대학교 컴퓨터공학과, ²인하대학교 전기컴퓨터공학과

qkrdyddnr@inha.edu, jkjeong@inha.edu, jekim@inha.ac.kr

A Hop-based Weighted Ensemble Approach for Class Imbalance

Yonguk Park⁰¹, Jaekyun Jeong², Jungeun Kim²¹Department of Computer Science and Engineering, Inha University²Department of Electrical and Computer Engineering, Inha University

qkrdyddnr@inha.edu, jkjeong@inha.edu, jekim@inha.ac.kr

요 약

머신러닝에서 클래스 불균형 문제는 데이터 분포의 편향으로 인해 모델이 다수 클래스에 과적합되고, 소수 클래스에 대한 예측 성능이 저하되는 현상을 초래한다. 이를 완화하기 위한 다양한 기법들이 제안되어 왔으며, 대부분은 클래스 간 샘플 수의 차이를 보정하는 데 초점을 두고 있다. 그러나 이러한 방법들은 데이터 분포의 왜곡이나 결정 경계의 정보 손실을 유발할 수 있다는 한계를 가진다. 최근 연구에서는 불균형 데이터셋의 성능 저하가 샘플 수 차이뿐 아니라 클래스 간 중첩(class overlapping)에도 기인함을 보여주고 있다. 본 연구에서는 이러한 클래스 간 중첩 문제를 분석하고, 이를 완화하기 위한 hop 기반 가중 앙상블 기법을 제안한다. 제안 방법은 소수 클래스를 중심으로 k-NN 그래프를 구성한 뒤, 다수 클래스 샘플을 hop 단위로 구분하여 개별 모델을 학습시키고, 이들을 거리 기반 가중 앙상블로 통합한다. OpenML-CC18의 19개 불균형 데이터셋을 대상으로 한 실험 결과, 제안 기법은 기존 방법 대비 소수 클래스 recall을 27.6% 향상시키면서도 f1-macro 성능을 유지하였다. 이를 통해 데이터 간 거리와 중첩을 함께 고려하는 hop 기반 접근법이 불균형 학습 문제에서 효과적인 전략임을 확인하였다.

1. 서 론¹

머신러닝은 데이터로부터 패턴을 학습하여 예측을 수행하는 핵심 기술로, 그 성능은 데이터의 품질에 크게 의존한다. 특히 클래스 불균형 문제는 모델이 다수 클래스에 편향되어 소수 클래스 탐지를 어렵게 한다. 이 문제를 해결하기 위한 대표적인 리샘플링 기법은 샘플 수 차이를 보정하지만 분포 왜곡이나 결정 경계 손실의 한계를 가진다[1]. 이러한 한계를 극복하기 위해, 데이터 분포의 보정 없이 모델 수준에서 불균형을 보정하는 방법들이 제안되었다. 최근 연구에서는 불균형 데이터셋에서의 성능 저하가 수직 불균형뿐 아니라 class overlapping에서도 기인함을 지적하였다[2]. Class overlapping이란 서로 다른 클래스에 속하는 샘플들이 비슷한 공간에서 뒤섞여 나타나 클래스 경계를 흐리는 현상을 말한다. 이는 모델의 일반화 성능을 저하시키는 원인 중 하나이다.

* 이 연구는 2025년도 산업통상자원부 및 산업기술평가관리원(KEIT) 연구비 지원(No.20022899)과 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원-대학ICT연구센터(ITRC)의 지원을 받아 수행된 연구임(IITP-2025-RS-2024-00438335).




그림 1 hop 거리에 따른 majority 샘플의 분포

그림 1과 그림 2의 실험을 통해 class overlapping이 모델의 성능에 미치는 영향을 분석하였다. 먼저 클래스 불균형을 부여한 무작위 2차원 이진 분류 데이터셋을 생성하였다. 각 샘플 간 유클리디안 거리를 계산한 뒤, k-NN(k=5) 기반 그래프를 생성하였다. 각 majority 샘플(파랑)들을 minority 샘플 집합(빨강)으로부터의 최소 hop 거리에 따라 구분하였다. 여기서 hop은 중심 노드 집합에서 해당 노드까지 도달하기 위해 지나야 하는 간선의 수를 뜻한다.



그림 2 결정 경계 시각화

그림 1은 minority 샘플 집합과 각 hop에 위치한 majority 샘플을 나타낸다. 그림 1을 통해, minority 샘플에 가까운 majority 샘플은 overlapping이 심하게 발생함을 볼 수 있다.

그림 2는 전체 minority 샘플들과 일부 majority 샘플을 사용하여 XGBoost[3]로 학습한 결정 경계를 시각화한 결과이다. 상단은 majority 샘플을 1-hop부터 순차적으로 누적하여 학습한 경우이고, 하단은 각 hop의 샘플만을 개별적으로 학습한 경우를 보여준다. 1-hop부터 누적하여 학습시킬 때에는 데이터를 추가하더라도 결정 경계가 크게 변하지 않는 것을 알 수 있다. 반면 hop별로 학습을 시키면 이전과 달리 각 hop별로 구별되는 결정 경계가 형성되며, hop 거리가 멀수록 minority class에 과적합되는 양상을 확인할 수 있다. 이는 특정 n-hop 샘플을 학습에 사용했을 때 n-hop보다 멀리 떨어진 샘플의 정보가 학습에 거의 반영되지 않는 것을 뜻한다. 또한 minority 샘플과 가까운 majority 샘플을 제거하면 minority recall은 향상되나, 과적합되어 전반적인 성능은 오히려 저하되는 trade-off 현상이 발생한다.

표 1 hop 거리에 따른 결과 (N은 최대 hop을 나타냄)

majority 샘플	minority recall	f1-macro
1-hop to N-hop	0.1888	0.5296
1-hop only	0.2222	0.5207
2-hop to N-hop	0.7444	0.4542
2-hop only	0.7555	0.4573
3-hop to N-hop	0.9333	0.2584
3-hop only	0.9333	0.2584

표 1은 실험 결과를 정량적으로 보여준다. 2차원 데이터에서 관찰된 이러한 구조적 패턴은 차원성과 무관한 메커니즘에 기반하므로, 고차원 데이터셋에서도 유사하게 유지될 것으로 기대된다. 이후 실험에서도 일관된 결과가 확인되어 이러한 가정의 타당성이 뒷받침된다.

따라서 본 연구는 hop 단위의 특성을 활용하여 클래스 불균형과 class overlapping 문제를 동시에 완화하고 minority 탐지 성능을 향상시킬 수 있는 접근법을 제안한다.

2. 방법론

2.1 hop 단위 개별 학습

Majority 샘플을 minority 샘플 집합으로부터의 최소 hop 단위로 분할하고, 각 hop 집합을 개별 분류 모델에 학습시킨다. 이후 각 모델의 출력을 soft voting 방식으로 집계하여 최종 예측을 수행한다. 전체 데이터를 단일 모델에 학습할 경우 멀리 있는 hop 샘플의 결정 경계가 충분히 반영되지 않는 문제가 존재한다. 개별 학습은 위 문제를 완화함으로써 minority class recall을 개선한다. 본 논문에서는 개별 모델로 XGBoost[3]를 사용하였고 i 번째 hop의 모델의 출력을 α_i 로 사용한다.

2.2 가중 앙상블

Soft voting 단계에서 모든 모델에 동일한 가중치를 부여하지 않고, hop 거리에 따라 차등적인 가중치를 적용하였다. 가까운 hop을 학습한 모델에는 상대적으로 높은 가중치를, 멀리 있는 hop을 학습한 모델은 기하감쇠를 적용하여 가중치를 점진적으로 감소시켰다. 이는 멀리 있는 샘플로 인해 모델이 minority class에 과적합되는 문제를 완화하기 위함이다. i 번째 hop의 모델의 가중치는 α^{i-1} ($0 < \alpha < 1$)로 나타낸다.

제안하는 두 가지 전략을 결합하여 minority recall 향상과 전체 성능 유지 간의 균형을 달성하고자 한다. 아래는 최종 클래스 예측 결과를 수식으로 나타낸 것이다.

$$C = \begin{cases} 1, & \frac{\sum \alpha_i \alpha^{i-1}}{\sum \alpha^{i-1}} > 0.5 \\ 0, & \text{otherwise.} \end{cases}$$

3. 실험

3.1 실험 방법 및 데이터셋

표 2 비교 기법 정리

범주	기법
Oversampling	Random OverSampling(ROS), SMOTE, ADASYN, Borderline-SMOTE(BSMOTE)
Undersampling	Random UnderSampling(RUS)
Hybrid	SMOTEENN(S-ENN), SMOTETomek(S-Tomek)
Loss-function	Class-Balanced Loss(CBloss)
Ensemble	Easy Ensemble(Ee)

OpenML-CC18 Benchmark suite[4]에서 imbalance ratio (IR)가 2.0 이상인 이진분류 데이터셋 19개를 사용하였다. 가장 불균형이 큰 데이터셋은 IR=17.54였으며 각 데이터셋은 10회 반복 실험을 수행하여 평균 성능을 비교하였다.

Baseline은 전체 데이터를 학습한 XGBoost[3] 모델이며, 평가 지표로 baseline 대비 minority recall과 f1-macro의 증가율을 사용하였다. 제안 기법을 표 2에 있는 다양한 클래스 불균형 기법들과 비교하여 성능을 비교하였고 샘플링 기법들은 샘플링 후 baseline에 학습시켜 성능을 비교하였다.

3.2 실험 결과

표 3은 제안 방법과 기존 불균형 처리 기법들의 성능을 비교한 결과이다. 제안 방법은 RUS와 EE를 제외한 모든 기법들보다 평균적으로 높은 minority recall을 보였으며, 표 4의 결과를 통해 f1-macro는 baseline과 통계적으로 유의한 차이가 없다는 것을 확인하였다. 이는 minority recall을 향상시키면서도 모델의 일반화 성능을 안정적으로 유지했음을 의미한다. 반면 RUS와 EE는 minority recall을 크게 향상시켰으나 f1-macro가 유의미하게 감소해 모델의 일반화 성능을 유지하지 못하는 경향을 보였다. 일부 기법들은 일반화 성능은 유지했으나 minority recall을 충분히 향상시키지 못했다. 제안 기법은 이러한 기존 방법들 대비 minority recall을 평균적으로 27.6% 높이면서도 f1-macro 성능을 유지하여, 불균형 데이터셋에서 recall과 안정성 간의 균형을 효과적으로 달성함을 확인했다.

표 3 실험 결과

	Model	Minority recall	f1-macro
Baseline	XGB	1.0000	1.0000
Over sampling	ROS	1.2801	1.0187
	SMOTE	1.2541	1.0185
	ADASYN	1.2542	1.0170
	BSMOTE	1.2591	1.0189
Under sampling	RUS	<u>1.8063</u>	0.9507
Hybrid	S-ENN	1.7192	1.0004
	S-Tomek	1.2644	1.0212
Loss-function	CBLoss	1.2791	1.0163
Ensemble	EE	<u>1.8442</u>	0.9397
Proposed	Proposed	<u>1.7828</u>	<u>0.9953</u>


표 4 f1-macro 통계적 유의성 검정

Model	f1-macro	
	t-test (p-value)	Wilcoxon test (p-value)
RUS	0.0000	0.0000
EE	0.0000	0.0000
Proposed	<u>0.1069</u>	<u>0.0116</u>

3.3 하이퍼파라미터 민감도

제안 기법에서는 hop 기반 가중치 앙상블을 위해 거리에 따라 가중치 감소율을 제어하는 하이퍼파라미터 α ($0 < \alpha < 1$)를 사용한다. α 가 클수록 hop에 따른 가중치 감소가 완만해져, 먼 hop의 데이터를 학습한 모델이라도 큰 가중치를 가지게 된다. 반대로 작을수록 먼 hop의 데이터를 학습한 모델의 가중치가 빠르게 감소한다.

그림 3의 결과를 통해 $\alpha=0.55$ 일 때 f1-macro는 유지하며 minority recall을 최대로 높일 수 있는 것을 확인하였다.

그림 3 하이퍼파라미터 α 민감도 실험 결과

4. 결론

본 연구는 기존 클래스 불균형 연구가 주로 클래스 간 데이터 수 차이에 집중했던 것과 달리, class overlapping 문제를 분석하고 이를 완화하기 위한 새로운 접근을 제안하였다. 실험을 통해 minority 샘플과 가까운 majority 샘플들이 멀리 있는 샘플의 영향을 상쇄하여 minority recall 향상을 억제하는 주요한 원인임을 확인하였다. 이를 해결하기 위해 제안한 hop 기반 가중치 앙상블은 overlapping 문제를 효과적으로 완화하면서 minority recall을 향상시키는 동시에 f1-macro를 안정적으로 유지하였다.

다만 제안 방법은 k-NN 기반 그래프 구축 과정에서 $O(N^2)$ 의 시간복잡도를 가진다. 이는 데이터의 규모가 커질수록 계산 비용이 급격하게 증가함을 의미한다. 향후 연구에서는 시간복잡도를 완화하면서도 성능을 유지할 수 있는 효율적 그래프 구축 방안을 탐구할 예정이다.

참고 문헌

- [1] Zhining Liu et al., "CLIMB: Class-imbalanced Learning Benchmark on Tabular Data", arXiv, arXiv:2505.17451.
- [2] Vuttipittayamongkol P., et al., "On the class overlap problem in imbalanced data classification", Knowledge-Based Systems, vol 212, pp. 105531, 2021.
- [3] Chen, Tianqi and Guestrin, Carlos, "XGBoost: A Scalable Tree Boosting System", in Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16), pp. 785-794, 2016.
- [4] Bernd Dischl et al., "OpenML Benchmarking Suites", in Proceedings of the 35th Conference on Neural Information Processing Systems - Datasets and Benchmarks Track (Round 2), 2021.